Fed-ISIC2019 학습 결과 (전체)

ISIC 2019, 3개 클라이언트(top3), EfficientNet-B0, 20라운드. 표시된 수치는 로그/결과 파일에서 직접 읽은 값이며, 평균·표준편차·합산은 스크립트로 계산했습니다. [확인] = 파일 값에서 바로 나온 사실, [해석] = 제 추정입니다.

1. 실험 설정

클라이언트 train 8937 / 2846 / 2423 (합계 14,206), val 1,578, test 3,946 (val_fraction=0.1, split_seed=0). batch 32, lr 1e-4, 연합 방법 local epoch 2, Centralized 1 epoch/라운드. 라운드별 모델 선택은 validation만 사용하고 test는 학습 종료 후 마지막 라운드 모델로 1회 평가(--final_test). 코드: GitHub NOWEAZ/Capstone-Design-II, 브랜치 fix/validation-split-and-metrics. 클래스(8): MEL, NV, BCC, AK, BKL, DF, VASC, SCC (FLamby 클래스 순서를 가정; test 샘플 수가 NV 1948로 최다인 점은 일치).

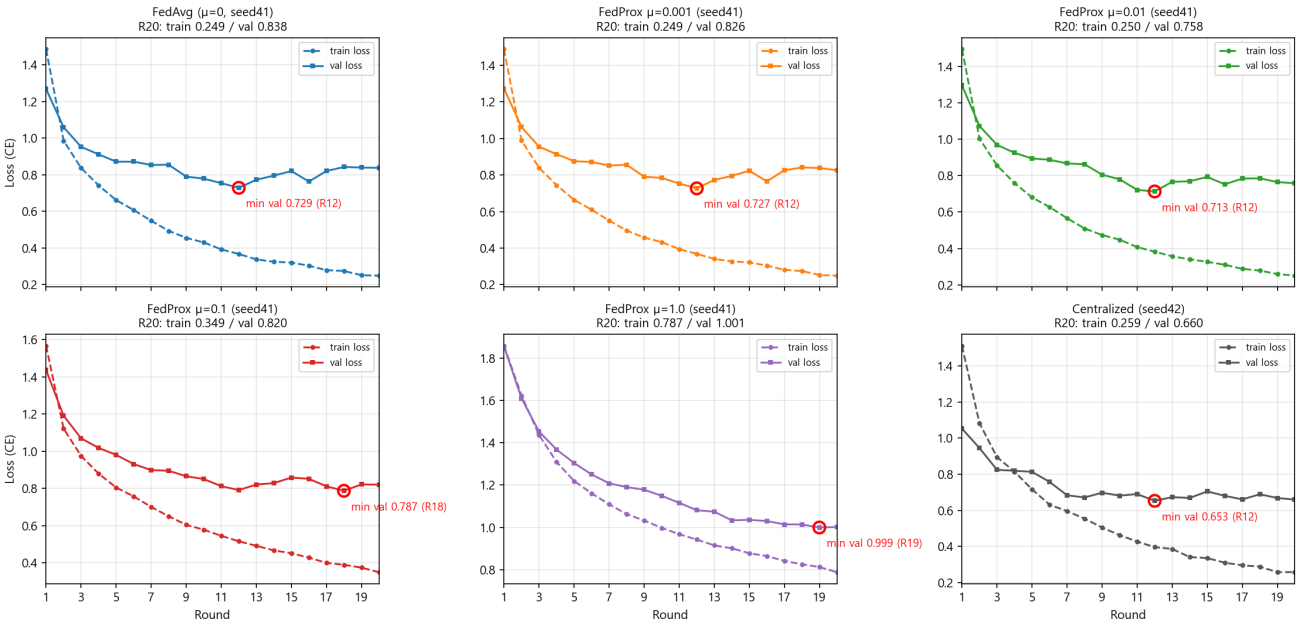
2. Stage 1 – FedProx μ 탐색 (seed 41, Validation)

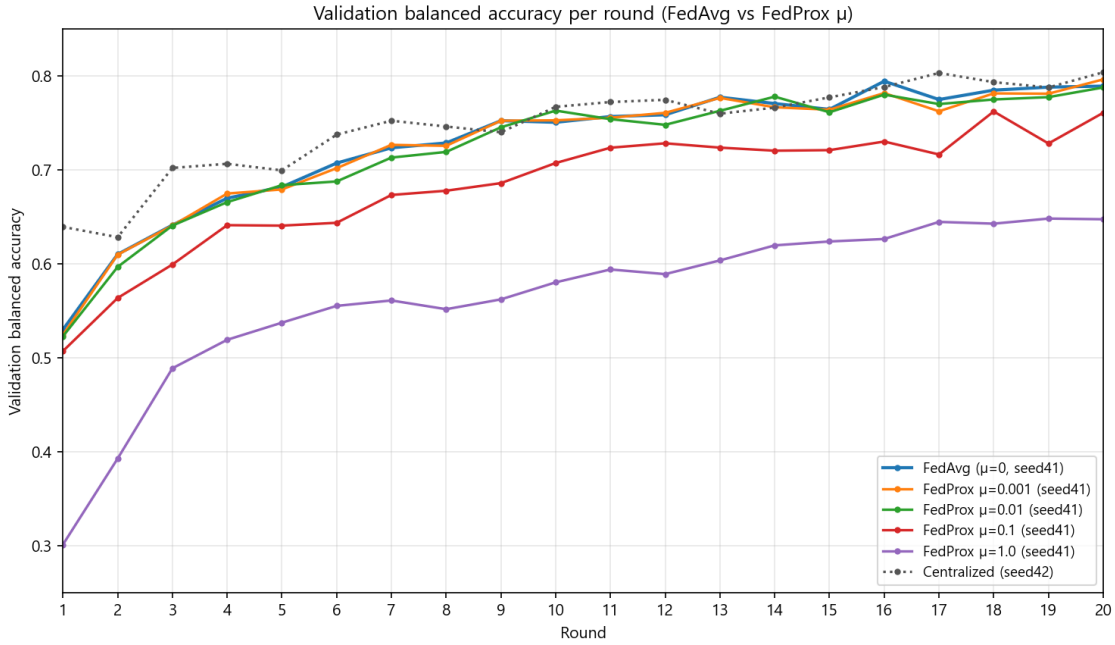
마지막 3라운드 Val Macro-F1 평균. 사전 규칙대로 FedProx 후보 중 최고인 μ=0.001을 선택.

방법	μ	Val Macro-F1	SD(3라운드)	Val Bal Acc	Val F1 Gap	Val ECE	Weight Div
FedAvg	0	0.7210	0.0336	0.7877	0.1937	0.0640	3.0208
FedProx	0.001	0.7225	0.0207	0.7866	0.2103	0.0603	2.9719
FedProx	0.01	0.7144	0.0193	0.7803	0.2061	0.0608	2.7139
FedProx	0.1	0.6701	0.0095	0.7506	0.1443	0.0347	1.8604
FedProx	1.0	0.5270	0.0044	0.6463	0.0694	0.0277	0.7820

[확인] μ=0.001과 FedAvg의 차이(+0.0015)는 라운드 간 변동(SD 0.02~0.03)보다 훨씬 작음. [확인] μ가 클수록 20라운드에서 성능이 낮음. [해석] μ≥0.1은 근접항이 강해 수렴이 느린 것으로 보임.

Fed-ISIC2019: train vs validation loss per round (빨간 원 = val loss 최저 라운드)





Validation 기준. Centralized는 seed42(다른 시드), 연합 방법은 seed41이라 곡선 간 직접 비교는 대략적임.

3. Stage 2 – Test 결과 (시드 42 / 100 / 2026, 마지막 라운드 모델)

방법	Bal Acc	Macro-F1	ECE	F1 Gap
Centralized	0.8114 ± 0.0116	0.7695 ± 0.0061	0.0479 ± 0.0065	0.1039 ± 0.0072
FedAvg	0.7762 ± 0.0114	0.7316 ± 0.0093	0.0680 ± 0.0049	0.1719 ± 0.0159
FedProx (μ=0.001)	0.7768 ± 0.0082	0.7306 ± 0.0114	0.0672 ± 0.0044	0.1691 ± 0.0120

3시드 평균 ± 표본 표준편차(n=3). Bal Acc = 균형 정확도, F1 Gap = 클라이언트 간 Macro-F1 격차(작을수록 균등), ECE = 보정 오차(작을수록 좋음).

방법	시드	Bal Acc	Macro-F1	ECE	F1 Gap
Centralized	42	0.8158	0.7724	0.0512	0.1018
FedAvg	42	0.7862	0.7390	0.0643	0.1784
FedProx (μ=0.001)	42	0.7843	0.7341	0.0641	0.1716
Centralized	100	0.8201	0.7626	0.0520	0.0980
FedAvg	100	0.7786	0.7212	0.0661	0.1834
FedProx (μ=0.001)	100	0.7780	0.7179	0.0651	0.1796
Centralized	2026	0.7983	0.7736	0.0404	0.1120
FedAvg	2026	0.7638	0.7347	0.0735	0.1538
FedProx (μ=0.001)	2026	0.7680	0.7398	0.0722	0.1560

시드 42 Centralized는 Colab, 나머지 8개는 Kaggle 실행. Kaggle 8개는 재실행해 결과 파일을 확보했으며, 재실행 값은 이전 로그에서 읽은 값과 소수점 4째 자리까지 일치(최대 차이 0.0000)했습니다.

참고: FLamby 공식 벤치마크 결과와의 비교

결과	클라이언트 수	시드 수	클라이언트별 test 평균 Bal Acc (평균 ± SD)	Pooled Test (합산 test)	논문 그래프 근사값(±0.02)
FLamby Pooled Training	6	5	0.7078 ± 0.0159	0.7622 ± 0.0102	약 0.71
FLamby FedAvg	6	5	0.5388 ± 0.0967	0.5339 ± 0.1140	약 0.54
FLamby FedProx (μ=0.001)	6	5	0.5437 ± 0.0740	0.5442 ± 0.0657	약 0.545
FLamby SCAFFOLD	6	5	0.5308 ± 0.0563	0.5593 ± 0.0725	약 0.535
FLamby FedAdam	6	5	0.5843 ± 0.0390	0.5753 ± 0.0090	약 0.585
우리 Centralized	3 (top3)	3	0.7673 ± 0.0123	0.8114 ± 0.0116	-

결과	클라이언트 수	시드 수	클라이언트별 test 평균 Bal Acc (평균 ± SD)	Pooled Test (합산 test)	논문 그래프 근사값(±0.02)
우리 FedAvg	3 (top3)	3	0.7074 ± 0.0066	0.7762 ± 0.0114	-
우리 FedProx (μ=0.001)	3 (top3)	3	0.7073 ± 0.0059	0.7768 ± 0.0082	-

FLamby 값: 공식 저장소(owkin/FLamby, main)의 flamby/results/results_benchmark_fed_isic2019/isic_seed42~46.csv 5개를 직접 읽어 집계(시드 5개). 지표는 balanced accuracy. '클라이언트별 test 평균'은 각 클라이언트 test의 Bal Acc를 시드마다 평균한 뒤 시드 평균·SD를 낸 값이고, 'Pooled Test'는 센터 전체를 합친 test의 Bal Acc. 우리 값은 저장한 test 예측(preds.npz)에서 클라이언트별 Bal Acc를 계산해 평균(클래스가 없는 센터는 존재하는 클래스만 사용). '논문 그래프 근사값'은 논문의 Fed-ISIC2019 막대그래프에서 눈금으로 읽은 근사값이며 정확한 값이 아님. 방법 이름은 CSV 표기(예: FedAvg100)를 옮긴 것.

• [확인] 논문 그래프의 막대(Pooled 약 0.71, FedAvg 약 0.54, FedProx 약 0.545, FedAdam 약 0.585 등)는 CSV의 '클라이언트별 test 평균'(0.708, 0.539, 0.544, 0.584)과 눈금 읽기 오차 안에서 일치함. 반면 CSV의 Pooled Test(0.762)는 그래프와 다르므로, 논문 그래프는 센터별 평균 집계로 보임. 로컬 단독 학습 막대(Client 0~5: 약 0.54/0.38/0.54/0.44/0.34/0.22)도 CSV의 클라이언트 평균(0.536/0.378/0.536/0.436/0.335/0.220)과 일치.

• [확인] 같은 기준(클라이언트별 평균)으로 우리 값은 Centralized 0.767, FedAvg 0.707, FedProx 0.707이고 FLamby(6클라이언트)는 Pooled Training 0.708, FedAvg 0.539, FedProx 0.544임. 연합 방법의 차이는 Pooled Test 기준 약 +0.24에서 클라이언트 평균 기준 약 +0.17로 줄지만 여전히 큼. Centralized 대 FLamby Pooled Training 차이는 약 +0.05(Pooled Test 기준)와 약 +0.06(클라이언트 평균 기준)으로 비슷함.

• [해석] 우리 클라이언트 0~2가 FLamby 센터 0~2와 같다고 가정하면(test 샘플 수 비율로 추정, 확인하지 못함) FLamby의 client 0~2 평균은 Pooled Training 0.744, FedAvg 0.604, FedProx 0.596(위 표 외 CSV 값)이라 우리 Centralized 0.767과는 비슷하고 연합 방법(0.707)은 약 +0.10 높음. 남는 차이는 클라이언트 수(3 대 6), 학습 설정(우리 Adam lr 1e-4, 20라운드, 가중 CE / FLamby CSV의 연합 방법은 SGD lr 0.01 등), 센터 구성 차이 때문일 수 있으나 어느 쪽이 원인인지는 검증하지 못함. 같은 설정으로 재실행해야 공정 비교 가능.

[확인] Centralized가 연합 방법보다 Bal Acc +3.5%p, ECE가 낮고, F1 Gap이 약 0.07 작음. FedAvg와 FedProx(μ=0.001)의 평균 차이는 모든 지표에서 시드 간 SD보다 작음. [해석] 시드 3개라 두 연합 방법의 우열은 결론 낼 수 없음.

4. 센터(클라이언트)별 Test Macro-F1

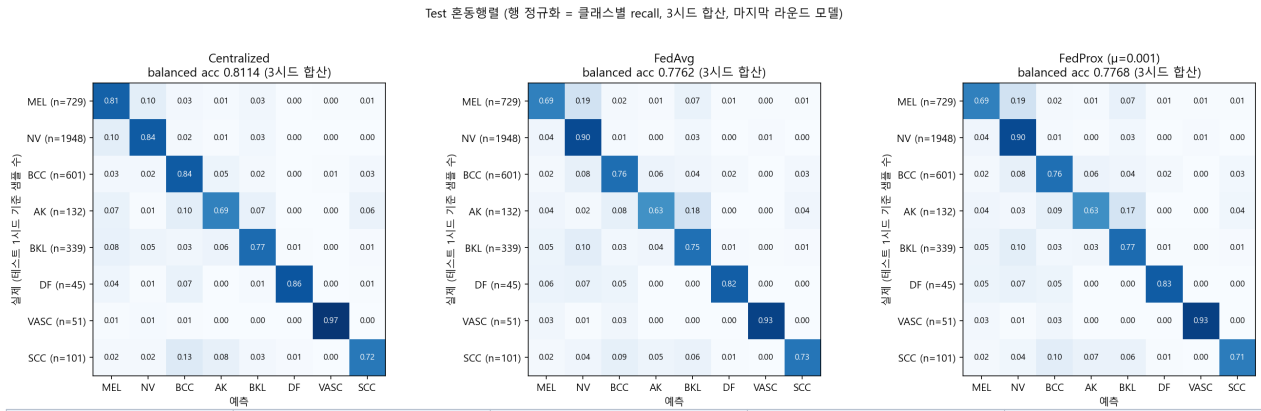
방법	client0 (n=2483)	client1 (n=791)	client2 (n=672)	격차 평균
Centralized	0.7627 ± 0.0067	0.7647 ± 0.0460	0.6744 ± 0.0185	0.1039
FedAvg	0.7666 ± 0.0076	0.5967 ± 0.0161	0.6048 ± 0.0168	0.1719
FedProx (μ=0.001)	0.7639 ± 0.0030	0.5972 ± 0.0142	0.6024 ± 0.0237	0.1691

3시드 평균 ± SD. 각 클라이언트 test 데이터에서 실제 존재하는 클래스만으로 계산한 macro-F1(present-class). 8클래스 고정 기준(fixed-8)은 client1에서 FedAvg 0.373, Centralized 0.478 등으로 더 낮으며 results/graphs/6_client_f1_table.csv에 있음.

• [확인] 가장 큰 센터(client0)는 세 방법 모두 0.76~0.77로 비슷함. 차이는 작은 센터에서 남: client1은 Centralized 0.765 vs FedAvg 0.597 / FedProx 0.597, client2는 0.674 vs 0.605 / 0.602.

• [해석] 연합 학습이 큰 센터의 분포에 끌려 작은 센터에서 성능이 낮아지는 전형적 이질성 영향으로 보이나, 이 데이터만으로 원인을 단정할 수는 없음.

5. 혼동행렬과 클래스별 Recall (Test, 3시드 합산)

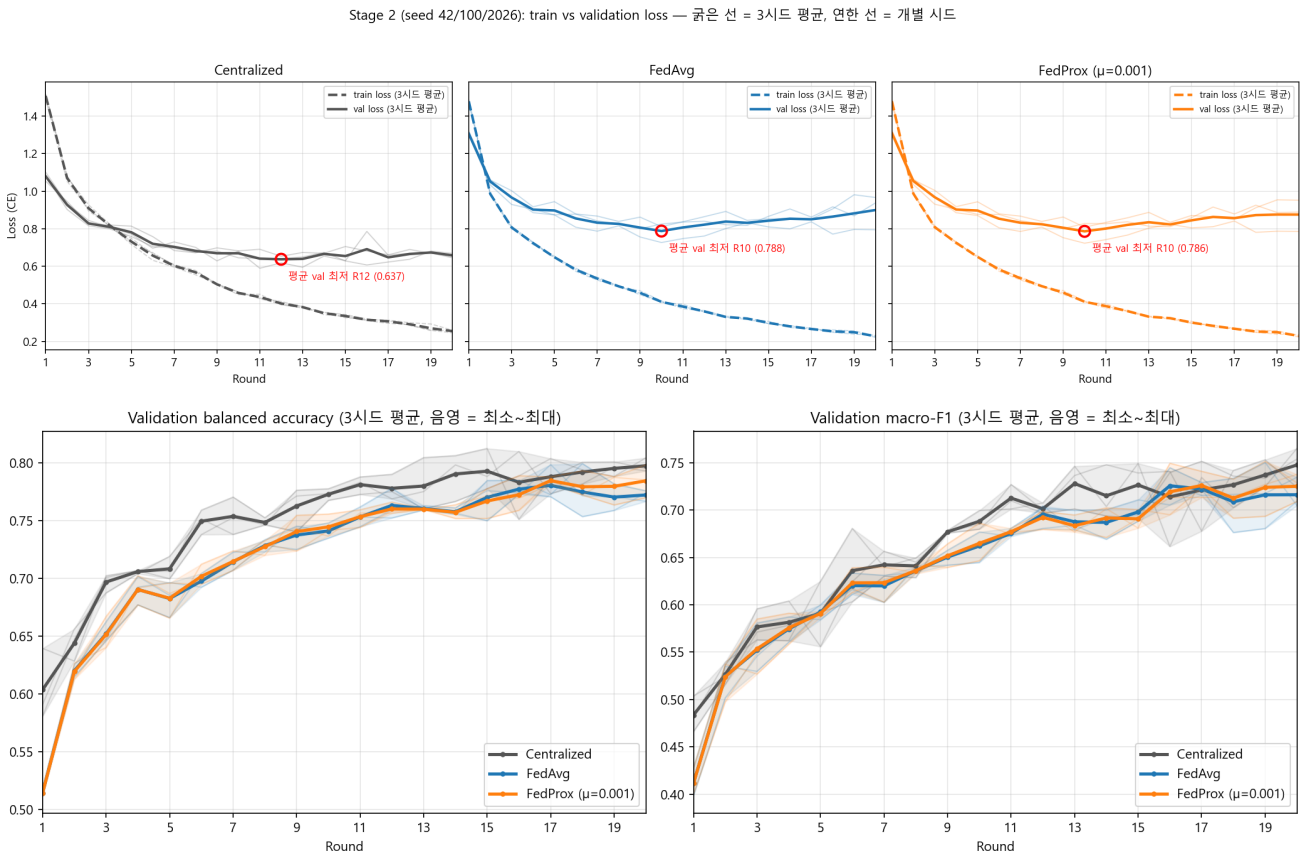


클래스	test n(시드당)	Centralized	FedAvg	FedProx
MEL	729	0.811	0.690	0.688

클래스	test n(시드당)	Centralized	FedAvg	FedProx
NV	1948	0.836	0.895	0.895
BCC	601	0.835	0.759	0.756
AK	132	0.687	0.629	0.634
BKL	339	0.770	0.753	0.770
DF	45	0.859	0.822	0.830
VASC	51	0.974	0.928	0.935
SCC	101	0.720	0.733	0.706

• [확인] 연합 방법은 NV recall이 높고(0.895 vs Centralized 0.836) MEL recall이 낮음(0.69 vs 0.81). AK→BKL 오분류가 연합에서 0.17~0.18로 Centralized(0.07)보다 큼. SCC→BCC는 Centralized에서 0.13.
• [해석] 연합 모델이 다수 클래스(NV) 쪽으로 치우치는 경향으로 보임. 임상적으로는 MEL(악성) recall 저하가 중요한 문제일 수 있음. 이 실험은 처음부터 역빈도 클래스 가중 Cross-Entropy를 사용했음(중앙집중은 전체 학습 분포, 연합은 병원별 로컬 분포 기준). 연합 모델의 NV 쪽 치우침과 MEL recall 저하는 가중을 쓴 상태에서도 나타났으므로 가중 미적용 때문이라고 해석할 수 없음. 개선을 시도한다면 더 강한 가중, focal loss, 전역 분포 기준 가중 등을 검토할 수 있으나 설계 변경이므로 팀이 결정할 사항임.

6. 학습 곡선과 과적합



• [확인] 3시드 평균 val loss 최저 라운드는 Centralized R12(0.637), FedAvg R10(0.788), FedProx R10(0.786). R20에서는 각각 0.658 / 0.900 / 0.876로, 연합 방법은 최저 대비 약 0.09~0.11 높음. train loss는 계속 감소(R20 평균 0.23~0.25).
• [확인] 3시드 평균 val Bal Acc 최근 5라운드: Centralized 0.783→0.797(상승), FedAvg 0.777→0.772(약간 하락), FedProx 0.772→0.784(소폭 상승).
• [해석] loss 기준으로는 연합 방법에서 R10 이후 약한 과적합 신호가 있으나, 분류 성능은 크게 떨어지지 않음. FedAvg는 마지막 라운드들에서 정체~소폭 하락으로 보이나 변동 범위 안일 수 있음.

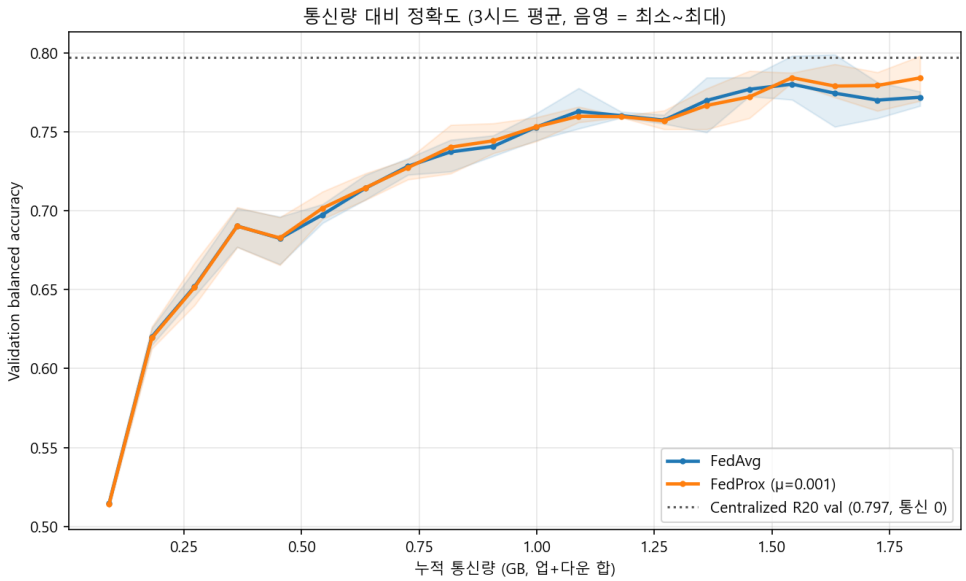
7. 마지막 라운드 모델 vs best-val 체크포인트 (Test)

방법	Bal Acc final	Bal Acc best-val	Macro-F1 final	Macro-F1 best-val	ECE final	ECE best-val
Centralized	0.8114	0.8051	0.7695	0.7471	0.0479	0.0509
FedAvg	0.7762	0.7747	0.7316	0.7157	0.0680	0.0649
FedProx (μ=0.001)	0.7768	0.7757	0.7306	0.7265	0.0672	0.0637

3시드 평균. best-val = 검증 balanced accuracy가 최고였던 라운드의 체크포인트(R15~R20, 시드별 값은 results/graphs/8_final_vs_bestval.csv). 시드별로는 best-val이 더 좋은 경우(예: seed2026 FedAvg 0.7790 vs 0.7638)와 나쁜 경우(seed100 Centralized 0.7990 vs 0.8201)가 섞임.

• [확인] 평균은 세 방법 모두 final이 best-val과 같거나 조금 높음(Bal Acc 차이 0.0010~0.0063). [해석] 검증 기준 체크포인트 선택의 이득이 일관되게 확인되지는 않음(시드 3개).

8. 통신량 대비 정확도



• [확인] 두 연합 방법 모두 20라운드 누적 통신량 약 1.81 GB(업+다운 합, 3 클라이언트)로 동일하고, 통신량 대비 val Bal Acc 곡선도 거의 겹침. 상위 구간(1.5 GB 이후)에서 FedProx가 근소하게 높으나 음영(최소~최대)이 겹침.

9. 한계와 파일 위치

• 시드 3개라 SD 추정이 거칠고, Stage 1(μ 선택)은 단일 시드(41)임. FedAvg와 μ=0.001은 사실상 동률이라 선택 자체가 변동에 민감함.

• Bal Acc 평균 SD: 본 PDF의 Centralized 0.0116은 비반올림 값으로 계산(앞선 간이 버전의 0.0115는 4자리 반올림 값 기반).

• 결과 파일: 이 저장소의 results/runs/ (Stage 1 5개 run의 metrics.csv, Stage 2 9개 run의 metrics.csv, final_test.json, final_test_preds.npz). 모델 체크포인트(.pt)는 저장소에 포함하지 않고 팀 Drive(CDII_results)에 있음. Kaggle에서 돌린 8개 run의 결과는 Drive와 Kaggle Output(Version 1)에도 있음(Drive는 총 60개 파일).

• 그림·표 원본: results/graphs/ (PNG, CSV).